

APRENDIZAJE PROBABLEMENTE APROXIMADAMENTE CORRECTO

Duvan Fernando Lombana Bejarano

3 de julio de 2026

1. Fundamento de la inferencia estadística.

Siguiendo la teoría de la Desigualdad de Hoeffding, podemos abarcar la situación de todo el universo posible de datos y la probabilidad de aprender con nuestro conjunto reducido de datos de entrenamiento, este escenario puede verse como una urna con un número desconocido de bolas verdes y rojas, de la que sacamos N bolas con reemplazo y nos interesamos en el valor de la fracción de muestras rojas ν (conocido) y el valor de la probabilidad de ocurrencia de las bolas rojas μ (desconocido). Esto se enlaza en la desigualdad:

$$P(|\nu - \mu| \geq \epsilon) \leq 2e^{-2N\epsilon^2}$$

La expresión en su lado izquierdo involucra la probabilidad de que ocurra un evento indeseable, específicamente la probabilidad de que la fracción de bolas rojas sacadas de la urna sea lejana de la verdadera proporción de bolas rojas en la urna por un margen mayor o igual a una tolerancia ϵ . Mientras que en su lado derecho se da un límite superior para esa probabilidad de equivocarse. Es importante notar que este término decae exponencialmente al aumentar la cantidad de muestras, esto implica que al añadir datos se reduce de forma exponencial el riesgo de fallar.

Por lo tanto, al tomar una muestra N lo suficientemente grande, para una tolerancia ϵ fija, el lado derecho de la ecuación será un número cercano a cero, así $P(|\nu - \mu| \geq \epsilon) \approx 0$, esto usando las leyes de la probabilidad es equivalente a $P(|\nu - \mu| < \epsilon) \approx 1$, en otras palabras, $\mu \approx \nu$ (la fracción de la muestra es aproximadamente igual a la verdadera probabilidad). Este argumento nos garantiza que con suficientes datos aleatorios, es bastante improbable que la muestra no se ajuste a la realidad, esto justifica por qué es posible entrenar un modelo con una muestra limitada de datos y lograr que funcione en la vida real.

2. Balance entre precisión y certeza.

En el mismo contexto de la Desigualdad de Hoeffding, tenemos la desigualdad

$$P(|E_{in}(g) - E_{out}(g)| \geq \epsilon) \leq 2Me^{-2N\epsilon^2}$$

donde $E_{in}(g)$ es el error de entrenamiento (*in-sample error*), $E_{out}(g)$ es el error de generalización (*out-of-sample error*), M se refiere al número (finito) de hipótesis, ϵ es el error tolerable entre los

errores y N es el número de datos necesarios. Definimos ahora $\delta = 2Me^{-2N\epsilon^2}$, con lo cual, nos enfocamos en la expresión

$$P(|E_{in}(g) - E_{out}(g)| \geq \epsilon) \leq \delta$$

Nos preguntamos si es más importante disminuir ϵ o δ , y además, en qué casos es más importante controlar cada uno.

Primero, observemos que a partir de la definición de δ , podemos despejar el número de datos N necesarios para el modelo, resultando así

$$N = \frac{1}{2\epsilon^2} \ln\left(\frac{2M}{\delta}\right)$$

A partir de esta expresión podemos determinar el precio que debemos pagar en el número de datos por disminuir alguno de los dos términos. En la mayoría de los escenarios la prioridad suele ser disminuir ϵ , es decir, mejorar la precisión, sin embargo esto es matemáticamente más caro, puesto que el costo de ϵ es cuadrático (al reducir ϵ a la mitad manteniendo los demás términos constantes, la cantidad N de datos se cuadruplica debido al término $\frac{1}{\epsilon^2}$). Por otro lado, el costo de δ es logarítmico gracias al término $\ln\left(\frac{2M}{\delta}\right)$, entonces disminuir δ no impacta de manera abrupta el número de datos. A pesar de esto, suele ser mejor tener un valor de ϵ pequeño, pues un modelo con un δ diminuto y un ϵ moderado estaría diciendo que es altamente probable que el error real del modelo no exceda un valor moderado, lo que no es para nada práctico.

El valor de ϵ se reduce cuando buscamos alta precisión, es decir, cuando queremos que el modelo mantenga la exactitud mostrada durante el entrenamiento en la vida real, reduciendo el riesgo de eventos atípicos, un ejemplo de este caso es la predicción de que un usuario le dé clic a un anuncio, aquí se busca que el margen entre el error de entrenamiento y el de generalización sea mínimo para poder proyectar ingresos, si el modelo falla catastróficamente una de cada mil veces por un valor de δ moderado, las consecuencias no son fatales.

Por otra parte, el valor de δ se reduce cuando un evento malo trae consecuencias o costos inaceptables, incluso aceptando en ciertos casos un límite de ϵ más tolerante, un ejemplo de este caso es un algoritmo para el diagnóstico de tumores malignos, aquí es necesario que la aproximación teórica del modelo funcione en la realidad, en otras palabras, se requiere que el riesgo de un fallo de generalización sea casi cero.